9. 가변수회귀모형

<병아리 성장률 & 칠면조 데이터 분석>

과 목	**응용휘귀분석 #1조**
날 짜	2025.12.08
문 제	연습문제 9-3, 9-4
코 드	박도연, 박성헌, 이용주, 전상우
보고서	박도연, 박성헌
발 표	박도연

9.3. 병아리 성장률 데이터 가변수회귀분석

병아리는 부화 직후부터 어미와 독립적으로 사료를 섭취할 수 있고 성장 속도가 빠르다는 점에서, 비타민 B 복합체의 생물학적 활성 정도와 요구량을 평가하는 표준 실험동물로 널리 이용되어 왔다(Coates, 1950). 1950 년대 이후부터 병아리를 이용하여 비타민 B 군(티아민, 리보플라빈, 판토텐산, 비타민 B6, 엽산 등)의 요구량과 효과를 측정하는 실험이 활발히 수행되었고, 이러한 연구들은 비타민 B 섭취량과 병아리 성장률 사이의 복용량–반응(dose-response) 관계를 밝히는데 기여하였다.

한편, 가금류에서 성별은 성장 패턴과 호르몬 등 다양한 생리 지표에 유의미한 영향을 미치는 것으로 알려져 있다. 일반적으로 수컷은 암컷보다 체중과 성장률이 높게 나타나는 결과가 보고된 바 있다(Yuan 등, 2024). 이러한 선행 연구를 고려하다면, 비타민 B 섭취량과 성장률 사이의 용량–반응 관계 또한 성별에 따라 그 기울기나 수준이 달라질 가능성이 있다. 따라서 성별을 단순한 교란변수로 처리하는 것을 넘어, 성별에 따른 차이를 모형화하고 검정하는 작업이 필요하다.

본 분석에서는 비타민 B 복용량(X)이 병아리 성장률(Y)에 미치는 복용량-반응(dose-response) 관계를 성별(Male/Female)에 따라 비교하고, 성별 효과의 유무를 통계적으로 검정하고자 한다. 특히, 양적인 독립 변수인 비타민 복용량(X)와 질적 범주형 변수인 성별을 함께 포함한 가변수 회귀모형을 설정하고,

1. 성별에 따른 기울기 차이(상호작용 효과)의 존재 여부
2. 성별에 따른 절편 차이(성별 고정 효과)의 존재 여부

를 유의수준 5%에서 검정함으로써, 단순히 두 변수의 개별적인 효과뿐만 아니라 성별에 따른 복용량 효과의 차이(상호작용 효과)까지 정량적으로 분리해 분석해보려 한다.

1 Dataset (data count: 32)

1. growth: 병아리의 성장률(종속 변수)

2. vitamin: 비타민 B 복용량

3. gender: 병아리의 성별 (범주형 변수 - Male, Female)-> gender_dummy(1,0)로 구성

	growth	vitamin	gender
	<dbl>	<dbl>	<chr>
1	17.1	0.301	m
2	14.3	0.0301	m
3	21.6	0.0301	m
4	24.5	0.0602	m
5	20.6	0.0602	m
6	23.8	0.0602	m
7	27.7	0.903	m
8	31	0.903	m
9	29.4	0.903	m
10	30.1	1.20	m

[Table 1] Data Structure

```
     growth          vitamin          gender
 Min.   :14.30   Min.   :0.0301   Length:32
 1st Qu.:23.23   1st Qu.:0.0602   Class :character
 Median :28.35   Median :0.9030   Mode  :character
 Mean   :27.50   Mean   :0.7770
 3rd Qu.:32.00   3rd Qu.:1.2040
 Max.   :40.20   Max.   :1.5050
```

[Table 2] Summary Statistics

1.1 Data Visualization

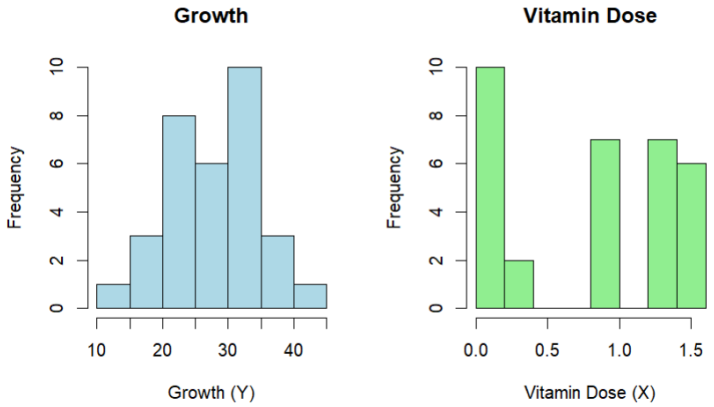

<Figure 1> Histogram

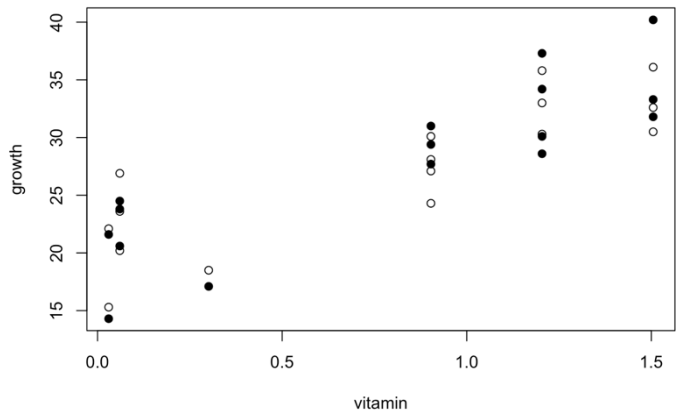

<Figure 2> Scatter Plot (White: female, Black: male)

Histogram 분석 결과, 성장률(Y)은 20에서 35 사이에 분포의 중심이 위치하며 뚜렷한 왜도(Skewness) 없이 비교적 대칭적인 정규분포 형태를 보였다. 이는 회귀분석의 잔차 정규성 가정을 충족할 가능성을 시사한다. 반면, 비타민 복용량(X)은 0.0, 0.0301, 0.903, 1.204 등의 특정 수준에 관측치가 집중된 형태를 나타내, 실험 설계 상 비타민이 특정 복용량으로 사전 설정 되어있음을 예상할 수 있다.

gender	N	mean_growth	sd_growth	mean_vitamin	sd_vitamin	min_growth	max_growth
<fct>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
f	16	27.2	6.11	0.768	0.582	15.3	36.1
m	16	27.8	7.14	0.786	0.592	14.3	40.2

[Table 3] Summary Statistics by gender

분석에 사용된 데이터는 Male과 Female 그룹 각각 16개씩, 총 32개의 관측치로 균형 잡힌 실험 설계를 이루고 있다. 통계치를 확인했을 때 대체로 Male(남성)이 Female(여성)보다 평균 성장률(Y)이 높고, 그 분포가 크게 나타난다.

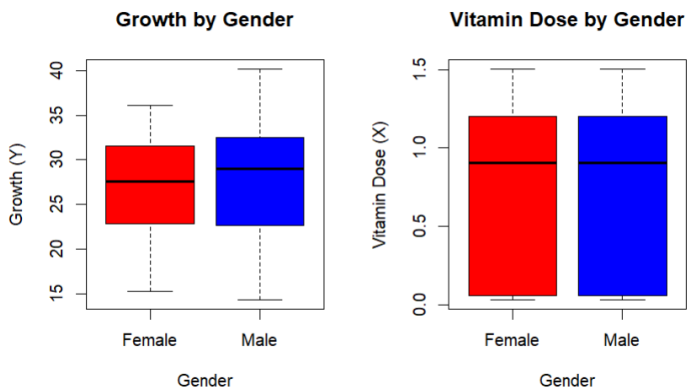

<Figure 3> Boxplot by Gender

Boxplot 분석 결과 전반적으로 심각한 이상치(outlier)는 관찰되지 않았다. 성장률(Y)의 경우, 데이터 통계치에서 확인했던 것처럼 Male(남성) 그룹이 Female(여성) 그룹보다 약간 더 높은 중앙값을 가지며, 더 넓은 사분위 범위(IQR)를 갖는다. 반면, 비타민 복용량(X)의 Boxplot은 성별 간에 중앙값과 분포의 형태가 거의 일치함을 확인할 수 있으며, 이는 비타민 투여가 성별 그룹에 대해 무작위적으로 잘 배정되었음을 나타낸다.

2. 문제 풀이_가변수회귀분석

(a) 성별에 따른 dose-response(비타민 복용량-반응) 직선 나타내기

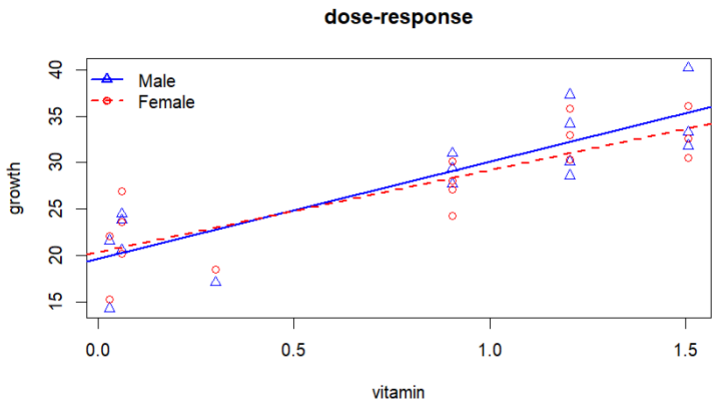

<Figure 4> dose-response Graph by Gender

산점도와 회귀직선을 통해 Male(남성)과 Female(여성) 그룹 모두 비타민 B 복용량이 증가할수록 성장률도 증가하는 강하고 명확한 양의 선형 관계를 확인할 수 있다. 이는 **비타민 B 투여가 병아리의 성장에 유의미한 영향을 미친다**는 실험적 가설을 뒷받침하는 결과이다. 또한 Male(남성)의 회귀 직선이 Female(여성)의 직선보다 약간 더 가파른 기울기를 가짐을 시각적으로 확인할 수 있다. 이를 통해 '비타민 복용량(X) 증가에 대한 성장률(Y)'이 Male(남성) 그룹에서 더 높을 가능성을 시사하며, 비타민 B 효과가 성별에 따라 다를 수 있다는 잠재적 차이로 생각할 수 있다. 더불어 두 직선은 복용량(X)이 0에 가까운 지점, 즉 비타민 투여가 거의 없을 때의 기본 성장률 수준에서 매우 유사하게 시작하고 있다. 이는 비타민B가 투여되지 않았을 경우 기본 성장 능력 자체는 성별 간에 큰 차이가 없음을 의미한다.

결론적으로, 성별 간에는 기울기의 미세한 차이가 관찰되지만, 이 차이가 통계적으로 유의미한 성별-복용량 상호작용 효과인지 판단하기 위해 다음 단계인 평행성 검정을 통해 통계적 유의성을 확인하고자 한다.

2.1. (M1) 병아리 성장률 데이터에 대한 가변수(gender) 상호작용 포함 회귀분석

```
Call:
lm(formula = growth ~ vitamin * gender_dummy, data = data)

Residuals:
    Min      1Q  Median      3Q     Max 
-5.6728 -2.3778  0.0407  2.0972  6.0106 

Coefficients:
                     Estimate Std. Error t value Pr(>|t|)    
(Intercept)            20.356      1.496  13.605 7.29e-14 ***
vitamin                 8.860      1.571   5.639 4.86e-06 ***
gender_dummy           -0.728      2.122  -0.343    0.734    
vitamin:gender_dummy    1.588      2.204   0.720    0.477    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.542 on 28 degrees of freedom
Multiple R-squared:  0.7353,	Adjusted R-squared:  0.7069 
F-statistic: 25.92 on 3 and 28 DF,  p-value: 3.125e-08
```

[Table 4] M1: full Model result

$$\hat{Y}(Growth)_{Female} = 20.356 + 8.860X(vitamin)$$
$$\hat{Y}(Growth)_{Male} = (20.356 - 0.728) + (8.860 + 1.588)X(vitamin)$$
$$= 19.628 + 10.448X(vitamin)$$

Gender 에 따른 병아리 성장률 예측 모델(M1)은 gender 종류와 가변수와의 상호작용을 포함해 위 식과 같이 구할 수 있다. M1 의 F-통계량은 매우 유의하게 나타났고 (p = 3.125e-08<0.05), R^2 값 역시 0.7069 로 높은 설명력을 보인다.
그러나 모델에 포함된 개별 변수를 확인했을 때, 성별 효과를 나타내는 gender_dummy (절편 차이) (p=0.734>0.05), vitamin:gender_dummy (기울기 차이) (p=0.477>0.05) 두 항

모두 통계적으로 유의하지 않게 나타났다. 특히 상호작용 항(vitamin:gender_dummy)의 비유의성은 시각적으로 관찰된 성별 간 기울기 차이가 통계적으로 무시해도 좋을 수준이며, **두 직선이 평행하다는 귀무가설을 기각할 수 없음**을 시사한다.

(b) 성별에 따라 기울기가 같다고 할 수 있는지 유의 수준 5%에서 검정(평행성 검정)

```
평행성 검정 (상호작용 항) P-value: 0.4772
```

[Table 5] vitamin:gender_dummy p-value result

평행성을 검정하기 위해 귀무가설(H_0=성별에 따른 기울기 차이가 없다.)을 검정한 결과 p-value: 0.4772>0.05 로 귀무가설(H_0)을 기각할 수 없다. 따라서, 성별에 따라 복용량-반응 직선의 기울기가 유의미하게 다르다고 할 수 없으며, **두 직선은 평행하다고 가정하는 것이 통계적으로 타당**하다.

2.2. (M2) 병아리 성장률 데이터에 대한 가변수(gender) 포함 회귀분석

```
Call:
lm(formula = growth ~ vitamin + gender_dummy, data = data)

Residuals:
    Min      1Q  Median      3Q     Max 
-6.2333 -2.0833 -0.1715  2.1340  6.5814 

Coefficients:
             Estimate Std. Error t value Pr(>|t|)    
(Intercept)   19.7367     1.2144  16.252 4.17e-16 ***
vitamin        9.6665     1.0928   8.845 9.89e-10 ***
gender_dummy   0.5056     1.2421   0.407    0.687    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.513 on 29 degrees of freedom
Multiple R-squared:  0.7303,	Adjusted R-squared:  0.7117 
F-statistic: 39.27 on 2 and 29 DF,  p-value: 5.581e-09
```

[Table 6] M2: parallel Model result

$$\hat{Y}(Growth)_{Female} = 19.7367 + 9.6665X(vitamin)$$
$$\hat{Y}(Growth)_{Male} = (19.7367 + 0.5056) + 9.6665X(vitamin)$$
$$= 20.2423 + 9.6665X(vitamin)$$

가변수와의 상호작용 항을 제외한(기울기 같음을 가정) 회귀식은 위 결과식처럼 구해진다. 모델의 F-통계량은 M1 과 마찬가지로 매우 유의하게 나타났고(p = 5.581e-09<0.05), R^2 값 역시 0.7117 로 기존 M1(0.7069)보다 높은 설명력을 보인다. 이를 통해 **불필요한 상호작용 항을 제거함으로써 모형의 간결성 대비 설명력이 향상**됨을 확인했다. 또한 비타민 복용량(vitamin)은 매우 유의하여(p=9.89e-10 < 0.05), 비타민 복용량

증가에 따른 성장 촉진 효과가 강력함을 확인할 수 있었다. 반면 gender_dummy 변수는 유의수준 5%에서 통계적으로 유의하지 않다(p=0.687>0.05). 이는 **두 직선이 평행하단 가정 하에서도 성별 간의 절편 차이(0.5056)가 유의미하지 않다는 것을 의미하며 성별은 성장률과 선형관계에서 유의한 영향이 없는 것**으로 볼 수 있다.

2.3. (M3) 추가 분석: 성별 변수를 제거한 가장 단순한 회귀모델

```
Call:
lm(formula = growth ~ vitamin, data = data)

Residuals:
    Min      1Q  Median      3Q     Max 
-5.9750 -2.1430 -0.1662  2.3527  6.3338 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)   19.984      1.037  19.269  < 2e-16 ***
vitamin        9.674      1.077   8.979 5.28e-10 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.464 on 30 degrees of freedom
Multiple R-squared:  0.7288,	Adjusted R-squared:  0.7198 
F-statistic: 80.62 on 1 and 30 DF,  p-value: 5.282e-10
```

[Table 7] M3: pooled Model(Gender 제거) result

$$\hat{Y}(Growth)_{Pooled} = 19.984 + 9.674X(vitamin)$$

성별 효과가 유의미하지 않다는 결과를 반영해 성별 변수가 성장률에 미치는 영향이 없다고 가정하여 절편과 기울기가 모두 동일하다고 가정한 가장 단순한 회귀모형(M3)을 적합해 보았다. 모델의 F-통계량은 매우 유의하게 나타났고(p = 5.282e-10<0.05), R^2 값 역시 0.7198 로 **세 모델 중 가장 높은 설명력**을 보인다. 다음 모델에 따르면 **복용량이 1 단위 증가할 때 성장률이 평균 9.674 단위 증가함**을 확인할 수 있다.

```
Model 1: growth ~ vitamin + gender_dummy
Model 2: growth ~ vitamin
  Res.Df    RSS Df Sum of Sq      F Pr(>F)
1     29 357.85                           
2     30 359.89 -1   -2.0449 0.1657 0.6869
```

[Table 8] M2(parallel model) vs M3(pooled model)

절편 차이가 통계적으로 유의한지 절편 효과를 검정하기 위해 추가로 M2, M3 두 회귀모형을 비교해보았다. 결과적으로 F-통계량은 유의하지 않으며(p=0.6869>0.05), 이는 M2 에서 M3 모델로 단순화했을 때 모델의 설명력이 통계적으로 유의하게 감소하지 않음을 보여준다. 따라서 **성별 변수가 성장률(Y)에 미치는 독립적인 영향이 유의미하지 않다**는 결론을 내릴 수 있다.

2.4. 최종 모형(M3)의 잔차 분석

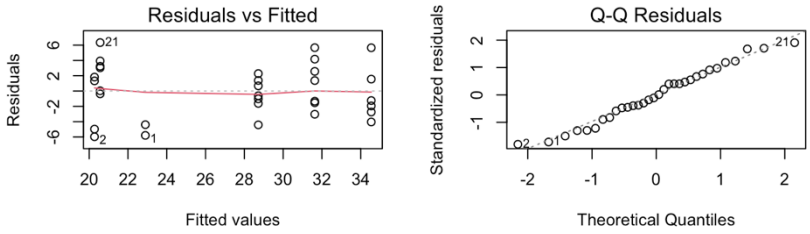

<Figure 6> 잔차 분석 Plot

잔차 분석 결과 잔차가 0을 중심으로 어떠한 경향이나 패턴이 없는 것으로 나타나고, Q–Q plot에서도 점들이 정규분포 기준선을 벗어나지 않고 분포하는 것으로 나타났다. 이는 전반적으로 오차에 대한 등분산성, 독립성, 정규성 가정이 크게 위배되지 않는다는 것을 시사한다. 따라서 최종적으로 채택한 **단순 선형회귀모형은 본 데이터에서 비타민 복용량과 병아리 성장률의 관계를 적절히 설명하는 모형**으로 판단된다.

3. 결론

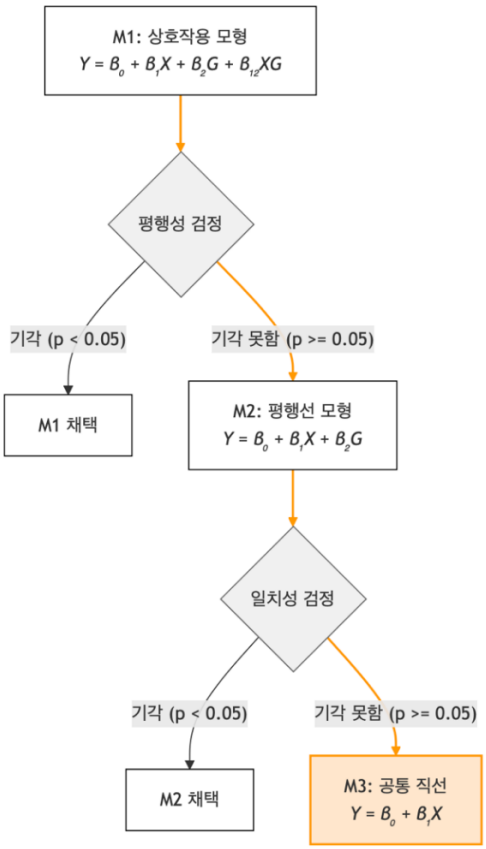

<Figure 6> 모형 선택 흐름도

본 분석에서는 비타민 B 복용량과 병아리 성장률 사이의 선형적인 용량–반응 관계를 추정하고, 이 관계에 성별이 유의한 조절 효과를 갖는지 검정하고자 하였다. gender_dummy 변수와 비타민 복용량의 상호작용 항을 포함한 가변수 회귀모형을 시작으로 단계적으로 비교한 결과, 성별에 따른 기울기 차이와 절편 차이는 모두 5% 유의수준에서 통계적으로 유의하지 않았다. 따라서 모형 선택 기준과 단계적 회귀 분석 결과를 종합해 모든 개체 데이터를 통합하여 분석한 단순 선형회귀모형 **M3 (Pooled Model: $\widehat{Y}(Growth)_{Pooled} = 19.984 + 9.674X(vitamin)$)**를 최종 모형으로 선택했다.

이러한 결과는 본 실험 조건과 비타민 B 복용량 범위 내에서, 병아리의 성별을 구분하지 않고 하나의 통합된 복용량–반응 직선을 적용하는 것이 통계적으로 타당함을 의미한다. 다시 말해, 비타민 B 복용량이 1 단위 증가할 때 성장률이 약 9.7 단위 증가하는 효과는 수컷과 암컷에서 유의미한 차이를 보이지 않았으며, **비타민 B 의 성장 촉진 효과가 성별에 관계없이 유사하게 나타난다**고 해석할 수 있다. 이는 비타민 B 요구량 및 효과를 추정할 때, 최소한 본 자료 수준에서는 성별을 별도로 구분하지 않고 분석해도 큰 왜곡이 발생하지 않다는 사실을 나타낸다.

다만, 본 분석은 표본 크기가 제한적이고, 특정 비타민 B 농도 범위 조건에 한정된 결과라는 점에서 해석에 주의가 필요하다. 향후 연구에서는 **개체 수 확대, 더 넓은 농도 범위와 다양한 환경을 포함**하여 비타민 B 복용량–성장률 관계를 재검증하는 한편, **성장률 외 지표를 함께 분석**한다면 성별 효과에 대한 보다 입체적인 이해가 가능할 것으로 기대된다.

4. 참고문헌

- 김재희, [R을 이용한 회귀분석 기초], 자유아카데미

9-4. 칠면조 데이터 가변수회귀분석

본 분석에서는 추수감사절용으로 사육된 칠면조를 대상으로, 나이(X, weeks)가 체중(Y, pound)에 미치는 나이-체중 관계가 원산지(Origin: Georgia, Virginia, Wisconsin)에 따라 유의미한 차이가 있는지 확인하고자 한다.

일반적으로 가금류의 성장 과정은 시간에 따른 체중 증가라는 연속적인 패턴을 보이지만, 사육 환경, 유전적 배경, 사료 구성 등이 다른 집단 간에는 동일한 성장 곡선을 따르지 않을 가능성이 있다. 특히 본 데이터에서는 세 지역별로 나이와 체중의 분포가 상이하게 나타나기 때문에, 단순한 평균 비교만으로는 원산지에 따른 체중 차이를 정확히 해석하기 어렵다. 이러한 점을 고려하여, 나이라는 양적 변수와 원산지라는 질적 범주형 변수를 동시에 포함한 회귀 모형을 설정하고, 나이를 통제한 상태에서 원산지 효과를 평가하는 관점으로 문제에 접근하고자 한다.

특히 질적 변수인 원산지(Origin)와의 복합적인 관계를 통계적으로 검정하기 위해,

1. 원산지에 따른 기울기 차이(성장률 차이)의 존재 여부
2. 원산지에 따른 절편 차이(기초 체중의 이질성)의 존재 여부

를 유의수준 5%에서 검정함으로써 가장 적합한 **칠면조의 성장 예측 회귀 모형**을 선정하는 것을 목표로 한다. 이렇게 도출된 모형은 나이와 원산지를 바탕으로 칠면조 체중을 예측하는 데 활용될 뿐만 아니라, 지역별 사육 성과의 차이를 통계적으로 해석하는 근거를 제공한다는 점에서 의의가 있을 것으로 기대된다.

1. Dataset (data count: 13)

1. X(Age): 추수감사절 칠면조의 나이(주, weeks)

2. Y(Weight): 추수감사절 칠면조의 무게(파운드, pound)

3. Origin: 원산지(Georgia (G), Virginia (V), Wisconsin (W))

4. z1, z2: 원산지 구분을 위한 가변수(G(1,0), V(0,1), W(0,0))

	x	y	Origin	z1	z2
	<dbl>	<dbl>	<chr>	<dbl>	<dbl>
1	28	13.3	G	1	0
2	20	8.9	G	1	0
3	32	15.1	G	1	0
4	22	10.4	G	1	0
5	29	13.1	V	0	1
6	27	12.4	V	0	1
7	28	13.2	V	0	1
8	26	11.8	V	0	1
9	21	11.5	W	0	0
10	27	14.2	W	0	0
11	29	15.4	W	0	0
12	23	13.1	W	0	0
13	25	13.8	W	0	0

[Table 3] Data Structure

```
       x               y            Origin              z1               z2
 Min.   :20.00   Min.   : 8.90   Length:13          Min.   :0.0000   Min.   :0.0000
 1st Qu.:23.00   1st Qu.:11.80   Class :character   1st Qu.:0.0000   1st Qu.:0.0000
 Median :27.00   Median :13.10   Mode  :character   Median :0.0000   Median :0.0000
 Mean   :25.92   Mean   :12.78                      Mean   :0.3077   Mean   :0.3077
 3rd Qu.:28.00   3rd Qu.:13.80                      3rd Qu.:1.0000   3rd Qu.:1.0000
 Max.   :32.00   Max.   :15.40                      Max.   :1.0000   Max.   :1.0000
```

[Table 4] Summary Statistics

1.1 Data Visualization

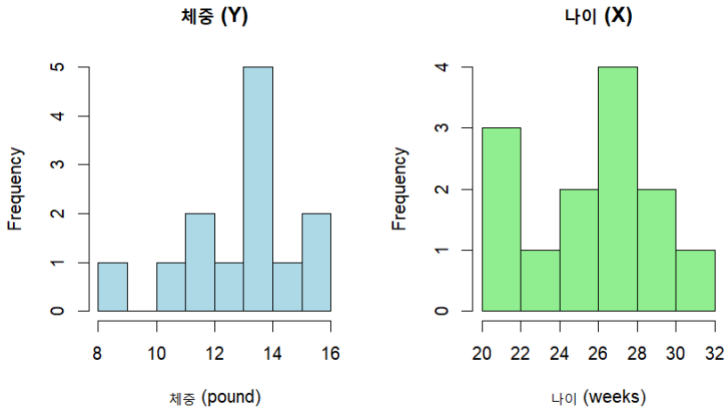

<Figure 2> Histogram

Histogram 분석 결과, 체중 분포의 중심은 12에서 14 파운드 사이에 위치하지만, **오른쪽으로 꼬리가 길게 늘어진 (Right Skewed) 형태를 보여 약간의 양의 왜도**가 관찰된다. 나이 분포는 20주부터 32주까지 비교적 넓게 퍼져 있으며, 26~28주 사이에 가장 많은 관측치가 집중되어 있다. 또한 상대적으로 심각한 왜곡 없이 **균일하게 분포하고 있다.**

	Origin	N	mean_Y	sd_Y	mean_X	sd_X
	<fct>	<int>	<dbl>	<dbl>	<dbl>	<dbl>
1	W	5	13.6	1.44	25	3.16
2	G	4	11.9	2.80	25.5	5.51
3	V	4	12.6	0.655	27.5	1.29

[Table 3] Summary Statistics by Origin

분석에 사용된 데이터는 Wisconsin(W)이 5 개, Georgia(G)와 Virginia(V)가 각각 4 개로, 각 지역별 그룹의 관측치 수는 균형적인 편이다. **Georgia(G)** 그룹이 체중(2.80)과 나이(5.51) 모두에서 가장 큰 표준편차를 보여, 다른 그룹에 비해 **데이터의 변동성이 가장 높음**을 알 수 있다. 또한 지역별로 나이 분포에 차이가 존재해 공분산 분석에서 나이(X)를 공변량(Covariate)으로 통제해야 할 필요성을 보여준다.

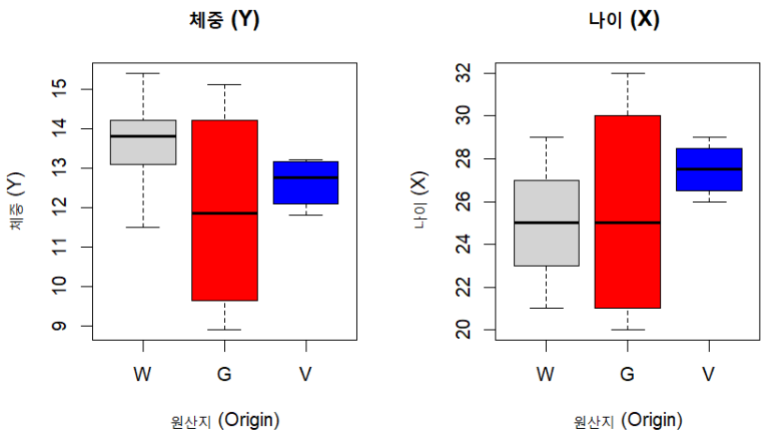

<Figure 3> Boxplot by Origin

Boxplot 분석 결과 Georgia(G) 그룹은 체중(Y)에 대해 중앙값이 가장 낮지만, 사분위 범위가 가장 넓어 위에서 확인했던 것처럼 데이터의 **변동성이 가장 큼**을 확인할 수 있다. 또한 나이 분포에서도 변동성(IQR 및 전체 범위)이 가장 커, 나이(X)가 **원산지 그룹에 따라 다르게 배정되었음**을 명확히 알 수 있다. 따라서 추후 분석에 단순히 그룹 간 평균을 비교 하는 것이 아니라 **나이(X)를 통제한 상태에서 원산지 효과를 정밀하게 분석**해야 할 필요성을 보인다.

2. 문제 풀이_가변수회귀분석 ((a), (b) 문제풀이는 각 과정에 포함됨)

2.1. (M1) 칠면조 데이터에 대한 가변수(Origin) 상호작용 포함 회귀분석

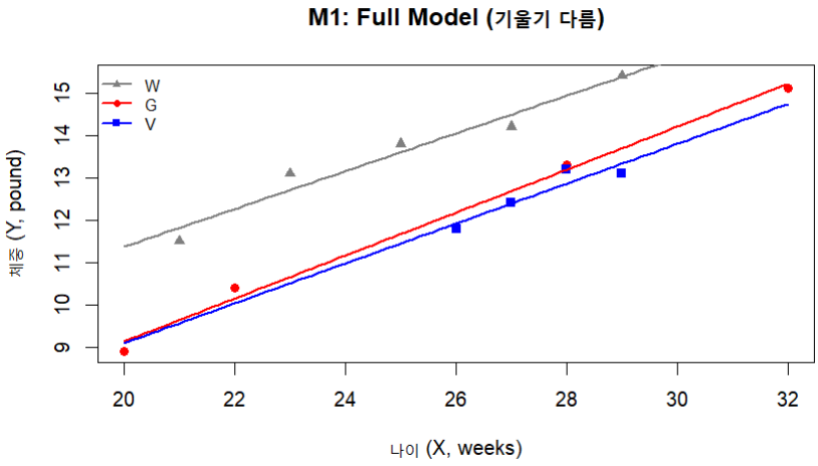

<Figure 3> plot of M1

산점도와 회귀직선을 통해 모든 지역에서 **나이가 증가할수록(시간이 흐를수록) 체중도 증가하는 강하고 명확한 양의 선형 관계**를 확인했고, 이를 통해 칠면조의 성장을 시각적으로 확인할 수 있다. 특히 W 지역은 어린 나이임에도 비교적 무거운 체중을 보이며 G,

V 지역과 구분된다. 또한 각 지역에서 회귀직선 간 미세한 기울기 차이가 관찰되지만, 정도가 크지 않아 이 차이가 통계적으로 유의미한 효과를 갖는지 평행성 검정을 통해 유의성을 확인하고자 한다.

```
Call:
lm(formula = y ~ x * Origin, data = data)

Residuals:
   Min     1Q Median     3Q    Max 
 -0.32  -0.23   0.01   0.20   0.39 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  2.47500    1.26351   1.959   0.0910 .  
x            0.44500    0.05022   8.861 4.72e-05 ***
OriginG     -3.45412    1.53054  -2.257   0.0586 .  
OriginV     -2.77500    4.10854  -0.675   0.5211    
x:OriginG    0.06104    0.06025   1.013   0.3447    
x:OriginV    0.02500    0.15066   0.166   0.8729    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.3176 on 7 degrees of freedom
Multiple R-squared:  0.9821,	Adjusted R-squared:  0.9693 
F-statistic: 76.74 on 5 and 7 DF,  p-value: 5.849e-06
```

[Table 4] M1: full Model result

$$\hat{Y}(weight)_W = 2.47500 + 0.44500X(Age)$$
$$\hat{Y}(weight)_G = (2.47500 - 3.45412) + (0.44500 + 0.06104)X(Age)$$
$$= -0.97912 + 0.50604X(Age)$$
$$\hat{Y}(weight)_V = (2.47500 - 2.77500) + (0.44500 + 0.02500)X(Age)$$
$$= -0.30000 + 0.47000X(Age)$$

원산지와 나이(X)의 상호작용을 포함한 M1의 F-통계량은 매우 유의하게(p=5.849e-06<0.05) 나타났고, adjusted R^2 값 역시 0.9693으로 높은 설명력을 보인다.

다만 모델에 포함된 개별 변수 중 원산지별 **기울기 차이를 나타내는 상호작용 항**인 x:OriginG(P=0.3447>0.05)와 x:OriginV(P=0.8729>0.05)는 모두 **통계적으로 유의하지 않다.** 이는 시각적으로 관찰된 원산지 간 기울기 차이가 우연일 가능성이 높음을 시사한다.

```
Model 1: y ~ x * Origin
Model 2: y ~ x + Origin
  Res.Df     RSS Df Sum of Sq      F Pr(>F)
1      7 0.70618                           
2      9 0.81118 -2    -0.105 0.5204 0.6156
```

[Table 5] M1 vs M2

세 지역에서의 평행성을 통합적으로 확인하기 위해 귀무가설(H_0=원산지에 세 직선의 기울기가 모두 같다.)을 검정한 결과 p-value: 0.6156>0.05로 귀무가설(H_0)을 기각할 수 없다. 따라서, 원산지에 따라 나이-체중 직선의 기울기가 유의미하게 다르다고 할 수 없으며, **세 직선은 모두 평행하다고 가정하는 것이 통계적으로 타당**하다.

2.2. (M2) 칠면조 데이터에 대한 가변수(Origin) 포함 회귀분석

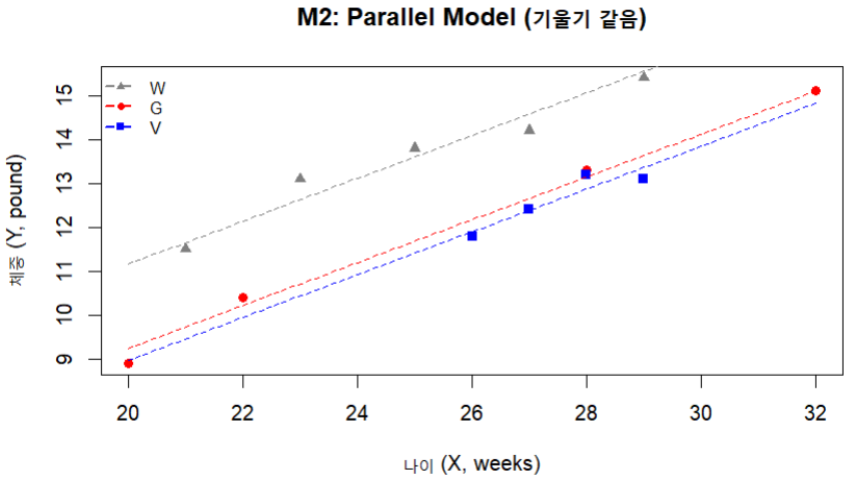

<Figure 4> plot of M2

```
Call:
lm(formula = y ~ x + Origin, data = data)

Residuals:
     Min       1Q   Median       3Q      Max 
-0.37353 -0.15294  0.01103  0.17868  0.47353 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  1.43088    0.65744   2.176   0.0575 .  
x            0.48676    0.02574  18.908 1.49e-08 ***
OriginG     -1.91838    0.20180  -9.506 5.45e-06 ***
OriginV     -2.19191    0.21143 -10.367 2.65e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.3002 on 9 degrees of freedom
Multiple R-squared:  0.9794,	Adjusted R-squared:  0.9726 
F-statistic: 142.8 on 3 and 9 DF,  p-value: 6.6e-08
```

[Table 6] M2: parallel Model result

$$\hat{Y}(weight)_W = 1.43088 + 0.48676X(Age)$$
$$\hat{Y}(weight)_G = (1.43088 - 1.91838) + 0.48676X(Age)$$
$$= -0.4875 + 0.48676X(Age)$$
$$\hat{Y}(weight)_V = (1.43088 - 2.19191) + 0.48676X(Age)$$
$$= -0.76103 + 0.48676X(Age)$$

상호작용 항을 제외한 모델 M2 의 F-통계량은 M1 과 마찬가지로 매우 유의하게 나타난다(p=6.6e-08<0.05). Adjusted R^2 값은 0.9726 으로 기존 M1 모델(0.9693)보다 높아 불필요한 상호작용 항을 제거함으로써 모형의 간결성 대비 설명력이 향상되었음을 확인할 수 있다. **M2 모델은 나이(X)를 공변량(Covariate)으로 통제한 공분산 분석의 최적 형태로 볼 수 있는데,** 이를 통해 **원산지(Origin) 변수가 체중에 미치는 순수한 주효과**를 정확하게 측정할 수 있다.

지역 간 절편 계수의 차이를 보면 OriginG(p=5.45e-06<0.05), OriginV(p=2.65e-06)으로 모든 지역에서 매우 유의하다. 즉 세 직선이 평행하다는 가정 하에서도 **원산지 그룹 간의 체중 기초 수준(절편) 차이**가 우연에 의한 것이 아니며 **칠면조의 원산지 자체가 나이를 통제한 이후에도 체중 수준에 유의미한 차이를 유발**한다는 사실을 알 수 있다.

2.3. (M3) 추가 분석: 원산지(Origin) 변수를 제거한 가장 단순한 회귀모델

```
Call:
lm(formula = y ~ x, data = data)

Residuals:
    Min      1Q  Median      3Q     Max 
-1.4167 -0.8333 -0.3500  0.9667  1.5333 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  1.98333    2.33273    0.85 0.413327    
x            0.41667    0.08922    4.67 0.000682 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.096 on 11 degrees of freedom
Multiple R-squared:  0.6647,	Adjusted R-squared:  0.6343 
F-statistic: 21.81 on 1 and 11 DF,  p-value: 0.0006824
```

[Table 7] M3: pooled Model(Origin 제거) result

$$\hat{Y}(weight)_{Pooled} = 1.98333 + 0.41667X(Age)$$

```
Model 1: y ~ x + Origin
Model 2: y ~ x
  Res.Df     RSS Df Sum of Sq     F    Pr(>F)    
1      9  0.8112                                 
2     11 13.2150 -2   -12.404 68.81 3.517e-06 ***
```

[Table 8] M2 vs M3

가변수인 원산지를 모두 제거한 M3 모델의 F-통계량은 여전히 유의하지만 (P=0.0006824<0.05), adjusted R^2 값은 0.6343으로 M2 모델(0.9726)에 비해 매우 낮은 설명력을 보인다. 이는 나이(X)만으로는 체중(Y) 변동의 약 63%만을 설명할 수 있으며, **원산지(Origin) 변수를 포함하는 것이 모델의 설명력을 압도적으로 향상**시킨다는 것을 의미한다. 추가로 M2와 M3의 절편을 비교하는 귀무가설(H_0=원산지 효과를 나타내는 절편의 차이가 없다.)을 검정한 결과 p-value: 3.1517e-06<0.05로 귀무가설(H_0)을 기각해 **원산지는 나이와 무관하게 체중 수준에 유의미한 영향을 미친다**는 결론을 내릴 수 있다.

2.4. 최종 모형(M2)의 잔차 분석

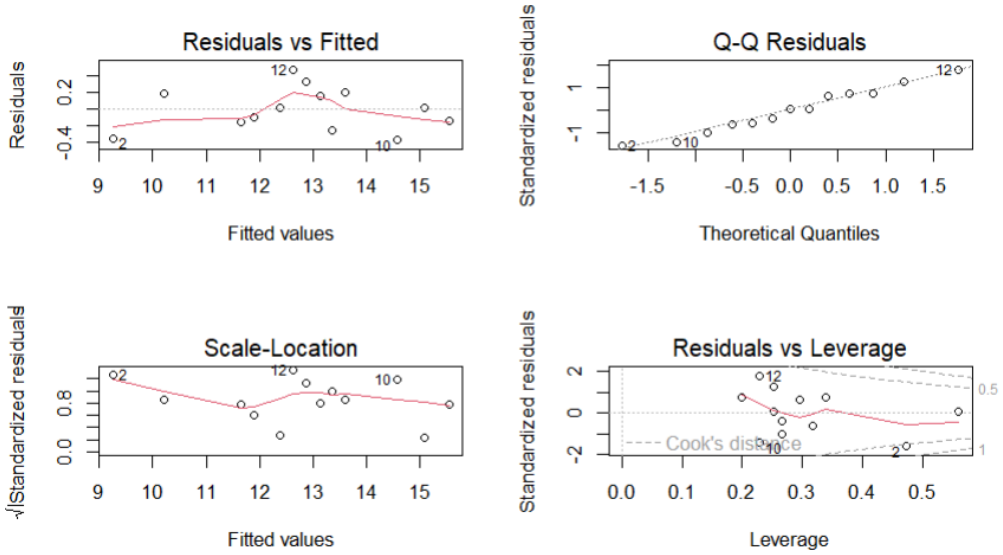

<Figure 6> 잔차 분석 Plot

잔차 분석 결과 Residuals vs Fitted plot 에서 잔차가 0 을 중심으로 완벽하게 랜덤하게 흩어져 있지는 않고, 예측값(12.5~14.5) 구간에서 양의 잔차를 보이는 약한 패턴이 관찰된다. 하지만 Scale-Location plot 에서는 잔차의 크기가 전반적으로 수평을 유지하여, 등분산성 가정이 심각하게 위배되지 않음을 보여준다. 또한 Q-Q plot 에서 데이터 포인트들이 중앙의 대각선 직선에 상당히 밀집하여 위치하여, 잔차의 정규성 가정은 대체로 충족하는 것으로 판단할 수 있다.

잔차 플롯에서 관찰된 약한 패턴은 **데이터 관측치 수(N=13)가 매우 적기 때문에 발생하는 노이즈**일 가능성이 높다고 판단된다. 따라서 현재 데이터(N=13)의 제약에도 불구하고 모형의 핵심 가정이 크게 위배되지 않았으므로 **M2 회귀모형은 본 칠면조 데이터에서 나이(X)와 원산지(Origin)가 체중(Y)에 미치는 관계를 적절히 설명하는 모형**으로 판단된다. 다만, 향후 더 많은 관측치를 포함하는 대규모 데이터를 확보하여 모형의 안정성을 재검증할 필요성이 있다.

3. 결론

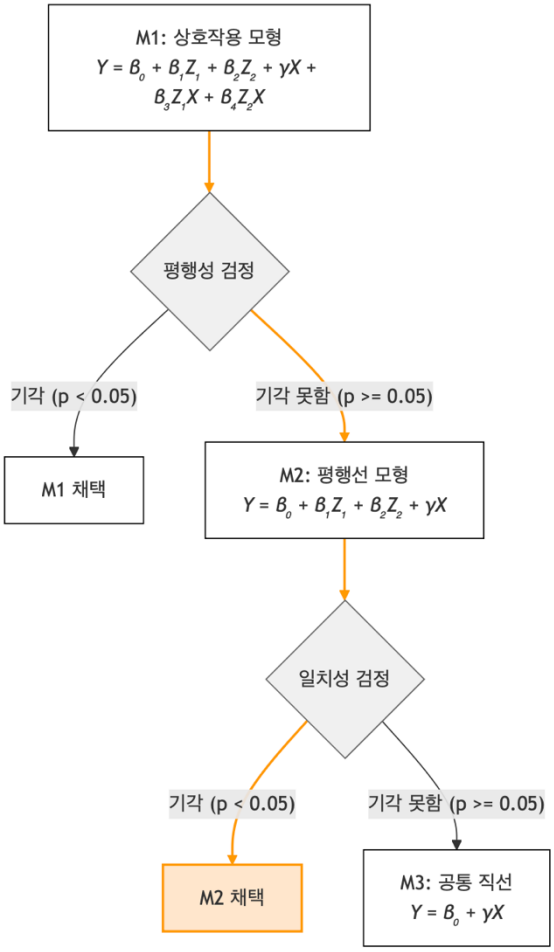

<Figure 5> 모형 선택 흐름도

종합적으로 단계적 회귀 분석 및 모형 선택 기준에 따르면, 원산지(Origin)를 가변수로 포함하되 기울기는 공통으로 가정한 모형 **M2 (Parallel Model:**

$$\hat{Y}(weight)_W = 1.43088 + 0.48676X(Age)$$
$$\hat{Y}(weight)_G = -0.4875 + 0.48676X(Age)$$
$$\hat{Y}(weight)_V = -0.76103 + 0.48676X(Age))$$

를 추수감사절 칠면조의 나이–체중 관계를 가장 잘 설명하는 최종 모형으로 선택했다. 나이(X)는 모든 모형에서 일관되게 체중(Y)에 대해 매우 유의한 양(+)의 효과를 가지는 것으로 나타났으며, 이는 나이 변수인 주(weeks)가 증가할수록 **칠면조의 체중이 주당 약 0.49 파운드씩 증가**한다는 해석으로 이어진다. 동시에 세 지역의 기울기가 통계적으로 구분되지 않았다는 사실은, **성장 속도 자체는 원산지와 무관하게 유사한 패턴**을 따른다는 점을 시사한다. 다시 말해, Georgia, Virginia, Wisconsin 에서 사육된 칠면조 모두 시간이 지남에 따라 비슷한 속도로 체중이 증가한다.

한편, 원산지에 따른 절편 차이, 즉 **원산지별 칠면조의 기초 체중에는 뚜렷한 차이가 존재**한다는 것을 알 수 있다. 특히 같은 나이에서 Wisconsin 지역 칠면조의 체중이 Georgia 및 Virginia 보다 유의하게 높게 나타나는 점은 **유전적 특성, 사육 환경, 사료 및 관리 방식 등 원산지에 연관된 요인들이 기초 체중 수준을 끌어올리는 방향**으로 작용하고 있을 가능성을 시사한다.

또한 원산지 변수를 제거한 단순 회귀모형(M3)의 설명력이 약 63% 수준에 머무른 반면, M2 모형에서는 약 97% 수준으로 크게 향상된 점을 고려하면, **원산지 정보를 포함하는 것이 칠면조 체중 예측과 원인 해석에 결정적인 역할을 한다**고 결론지을 수 있다. 이는 실무적으로도, 동일한 나이의 칠면조를 확보하려는 상황에서 어떤 지역의 공급자를 선택하는가에 따라 기대 체중이 달라질 수 있음을 의미하며, 사육 전략 수립이나 지역별 브랜드 가치 평가에도 참고할 수 있는 통계적 근거로 사용할 수 있다.

4. 참고문헌

- 김재희, [R을 이용한 회귀분석 기초], 자유아카데미

APPENDIX_실행 코드 모음

9.3

응용회귀분석 1 조

```
getwd()
setwd("C:/Users/user/Documents/R_DA")
library(readxl)
library(car)
library(corrplot)

data <- read_excel("table9.3_chick.xlsx")
data

## # A tibble: 32 × 3
##    growth vitamin gender
##     <dbl>   <dbl> <chr>
##  1   17.1  0.301  m
##  2   14.3  0.0301 m
##  3   21.6  0.0301 m
##  4   24.5  0.0602 m
##  5   20.6  0.0602 m
##  6   23.8  0.0602 m
##  7   27.7  0.903  m
##  8   31    0.903  m
##  9   29.4  0.903  m
## 10   30.1  1.20   m
## # ℹ 22 more rows

str(data)

## tibble [32 × 3] (S3: tbl_df/tbl/data.frame)
##  $ growth : num [1:32] 17.1 14.3 21.6 24.5 20.6 23.8 27.7 31 29.4
30.1 ...
##  $ vitamin: num [1:32] 0.301 0.0301 0.0301 0.0602 0.0602 ...
##  $ gender : chr [1:32] "m" "m" "m" "m" ...

head(data)

## # A tibble: 6 × 3
##   growth vitamin gender
##    <dbl>   <dbl> <chr>
## 1   17.1  0.301  m
## 2   14.3  0.0301 m
## 3   21.6  0.0301 m
## 4   24.5  0.0602 m
## 5   20.6  0.0602 m
## 6   23.8  0.0602 m

summary(data)
```

```
##      growth         vitamin          gender
##  Min.   :14.30   Min.   :0.0301   Length:32
##  1st Qu.:23.23   1st Qu.:0.0602   Class :character
##  Median :28.35   Median :0.9030   Mode  :character
##  Mean   :27.50   Mean   :0.7770
##  3rd Qu.:32.00   3rd Qu.:1.2040
##  Max.   :40.20   Max.   :1.5050
```

```r
data$gender <- factor(data$gender)

data_male <- subset(data, gender == "m")
data_female <- subset(data, gender == "f")

# 기술통계량
library(dplyr)

summary_stats <- data %>%
  group_by(gender) %>%
  summarise(
    N = n(),
    mean_growth = mean(growth),
    sd_growth = sd(growth),
    mean_vitamin = mean(vitamin),
    sd_vitamin = sd(vitamin),
    min_growth = min(growth),
    max_growth = max(growth)
  )

print(summary_stats)
```

```
## # A tibble: 2 × 8
##   gender     N mean_growth sd_growth mean_vitamin sd_vitamin min_growth
##   <fct>  <int>       <dbl>     <dbl>        <dbl>      <dbl>      <dbl>
## 1 f         16        27.2      6.11        0.768      0.582       15.3
## 2 m         16        27.8      7.14        0.786      0.592       14.3
## # ℹ 1 more variable: max_growth <dbl>
```

```r
# 히스토그램 (Histogram)
par(mfrow=c(1, 2))

hist(data$growth,
     main = "Growth",
     xlab = "Growth (Y)",
     ylab = "Frequency",
     col = "lightblue")

hist(data$vitamin,
     main = "Vitamin Dose",
     xlab = "Vitamin Dose (X)",
     ylab = "Frequency",
     col = "lightgreen")
```

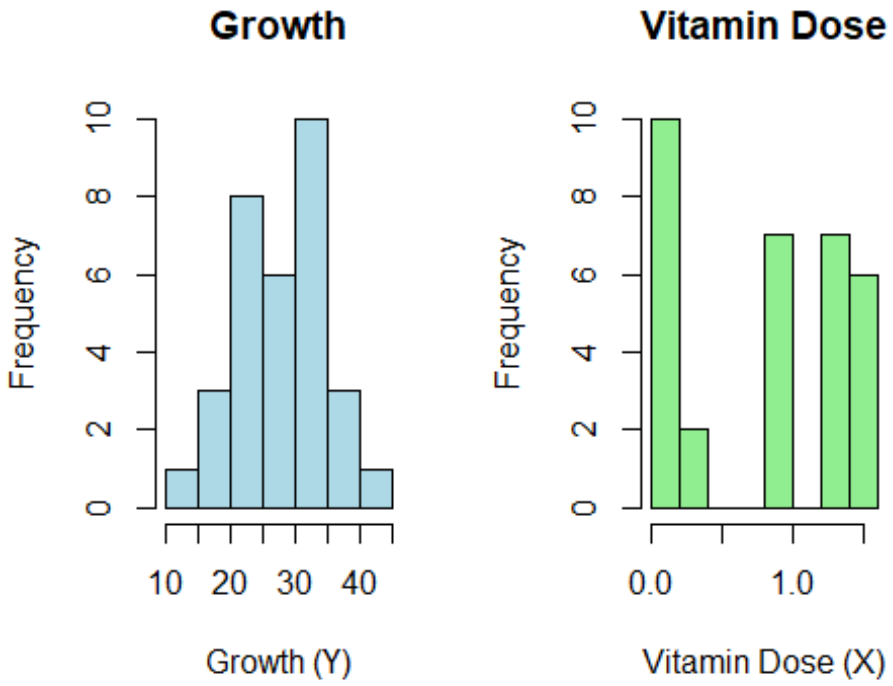


```r
# 박스플롯 (Boxplot)

boxplot(growth ~ gender, data = data,
        main = "Growth by Gender",
        xlab = "Gender",
        ylab = "Growth (Y)",
        col = c("red", "blue"),
        names = c("Female", "Male"))

boxplot(vitamin ~ gender, data = data,
        main = "Vitamin Dose by Gender",
        xlab = "Gender",
        ylab = "Vitamin Dose (X)",
        col = c("red", "blue"),
        names = c("Female", "Male"))
```

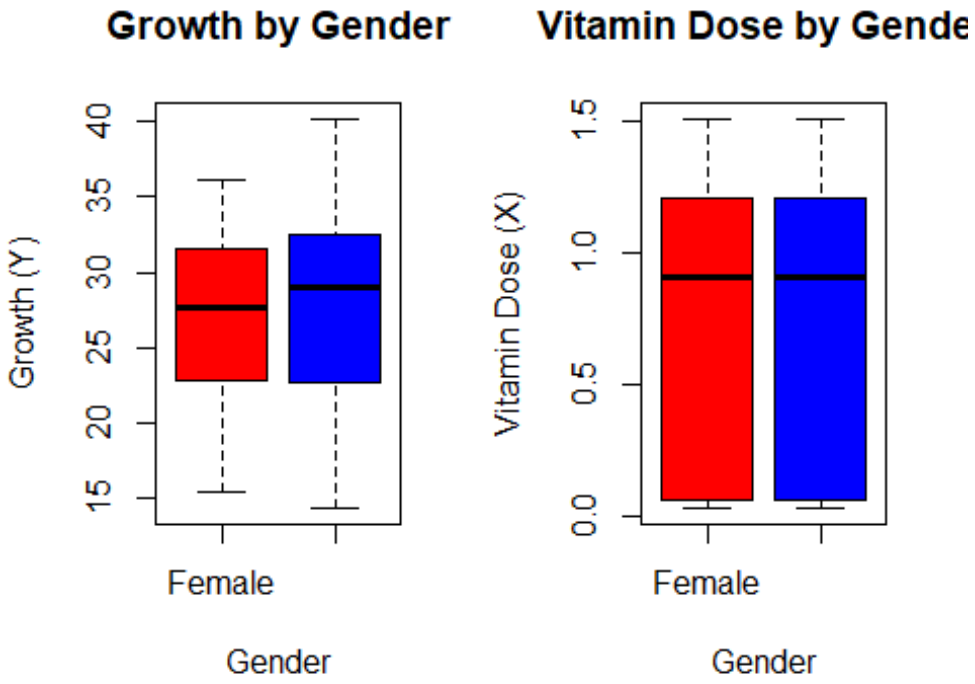


```r
par(mfrow=c(1, 1))


# (a) 성별에 따른 dose-response 직선 나타내기
x_range <- range(data$vitamin)
y_range <- range(data$growth)

plot(data$vitamin, data$growth,
     type = "n",
     xlab = "vitamin",
     ylab = "growth",
     main = "dose-response",
     xlim = x_range,
     ylim = y_range
)

# Male 데이터
points(data_male$vitamin, data_male$growth,
       pch = 2,
       col = "blue")

# Female 데이터
points(data_female$vitamin, data_female$growth,
       pch = 1,
       col = "red")

# Male 회귀 직선
```

```r
model_male <- lm(growth ~ vitamin, data = data_male)
abline(model_male, col = "blue", lwd = 2, lty = 1)
print(coef(model_male))
```

```
## (Intercept)     vitamin
##    19.62799    10.44781
```

```r
# Female 회귀 직선
model_female <- lm(growth ~ vitamin, data = data_female)
abline(model_female, col = "red", lwd = 2, lty = 2)
print(coef(model_female))
```

```
## (Intercept)     vitamin
##   20.356023    8.859654
```

```r
# 범례
legend("topleft",
       legend = c("Male", "Female"),
       col = c("blue", "red"),
       pch = c(2, 1),
       lwd = 2,
       lty = c(1, 2),
       bty = "n")
```

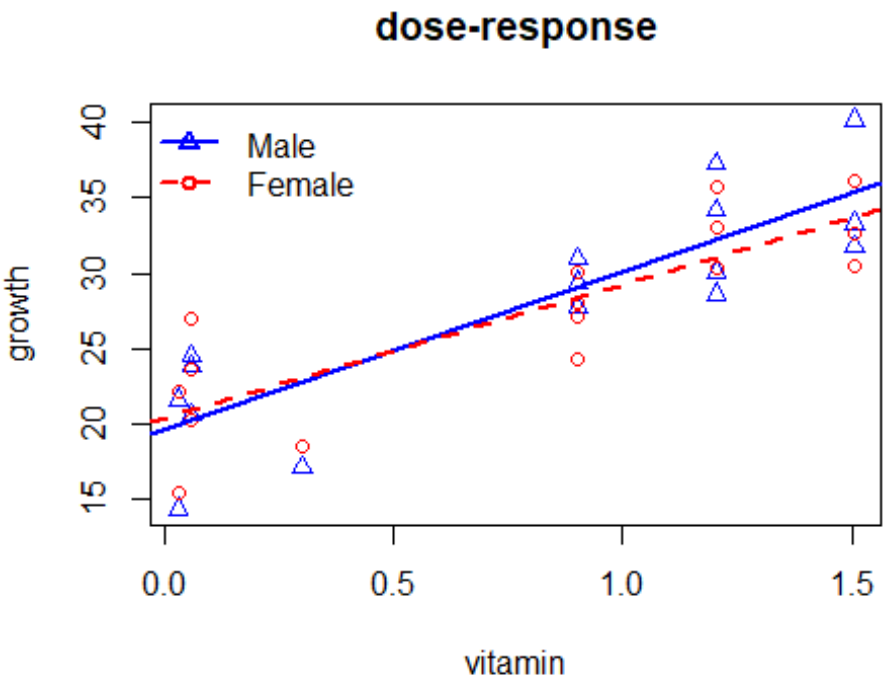


```r
# 병아리 성장률 데이터에 대한 가변수(gender) 상호작용포함 회귀분석(M1: Full
Model)
data$gender_dummy <- as.numeric(data$gender) - 1 # Male=1, Female=0
model_full <- lm(growth ~ vitamin * gender_dummy, data = data)
print(summary(model_full))
```

```
##
## Call:
## lm(formula = growth ~ vitamin * gender_dummy, data = data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -5.6728 -2.3778  0.0407  2.0972  6.0106
##
## Coefficients:
##                     Estimate Std. Error t value Pr(>|t|)
## (Intercept)           20.356      1.496  13.605 7.29e-14 ***
## vitamin                8.860      1.571   5.639 4.86e-06 ***
## gender_dummy          -0.728      2.122  -0.343    0.734
## vitamin:gender_dummy   1.588      2.204   0.720    0.477
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.542 on 28 degrees of freedom
## Multiple R-squared:  0.7353, Adjusted R-squared:  0.7069
## F-statistic: 25.92 on 3 and 28 DF,  p-value: 3.125e-08
```

```r
c0 <- model_full$coefficients[[1]]
c1 <- model_full$coefficients[[2]]
c2 <- model_full$coefficients[[3]]
c3 <- model_full$coefficients[[4]]

grid <- seq(min(data$vitamin), max(data$vitamin), length.out = 100)
M1_male_line <- (c0 + c2) + (c1 + c3) * grid
M1_female_line <- c0 + c1 * grid

plot(data$vitamin, data$growth,
     pch = data$gender_dummy + 1,
     col = ifelse(data$gender_dummy == 1, "blue", "red"),
     xlab = "vitamin",
     ylab = "growth",
     sub = "Male(=1), Female(=0)")
legend("topleft",
       c("Male", "Female"),
       pch = c(2, 1),
       col = c("blue", "red"),
       lty = c(1, 2),
       bty = "n")

lines(grid, M1_male_line, col = "blue", lty = 1, lwd = 2)
lines(grid, M1_female_line, col = "red", lty = 2, lwd = 2)
```

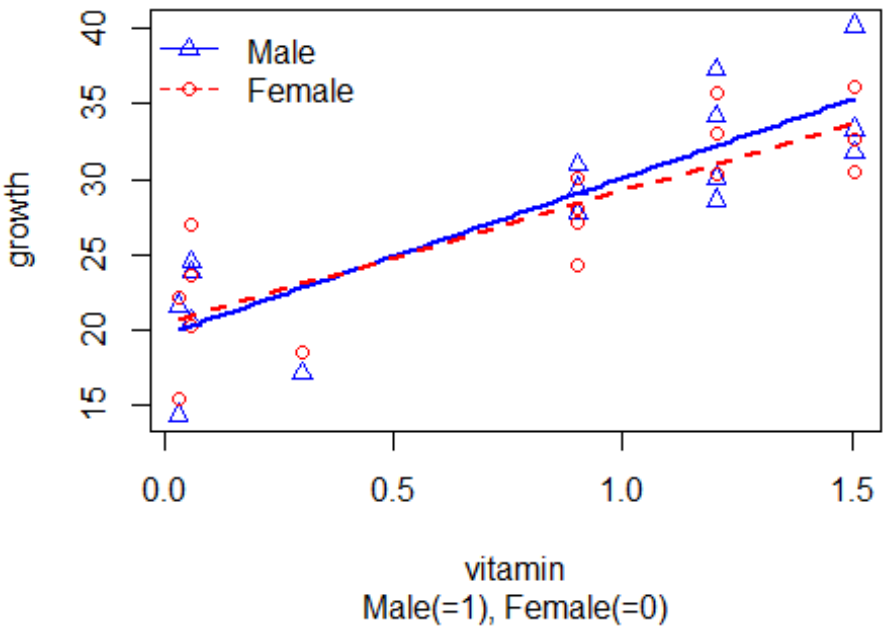


```
# (b) 성별에 따라 기울기가 같다고 할 수 있는지 유의 수준 5%에서 검정(평행성 검정)
p_value_interaction <-
summary(model_full)$coefficients["vitamin:gender_dummy", "Pr(>|t|)"]
cat(paste("\n 평행성 검정 (상호작용 항) P-value:", round(p_value_interaction,
4), "\n"))

##
## 평행성 검정 (상호작용 항) P-value: 0.4772

# 병아리 성장률 데이터에 대한 가변수(gender) 포함 회귀분석(M2: Parallel Model)
model_parallel <- lm(growth ~ vitamin + gender_dummy, data = data)
print(summary(model_parallel))

##
## Call:
## lm(formula = growth ~ vitamin + gender_dummy, data = data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -6.2333 -2.0833 -0.1715  2.1340  6.5814
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   19.7367     1.2144  16.252 4.17e-16 ***
## vitamin        9.6665     1.0928   8.845 9.89e-10 ***
## gender_dummy   0.5056     1.2421   0.407    0.687
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 3.513 on 29 degrees of freedom
## Multiple R-squared:  0.7303, Adjusted R-squared:  0.7117
## F-statistic: 39.27 on 2 and 29 DF,  p-value: 5.581e-09

b0_parallel <- model_parallel$coefficients[[1]]
b1_parallel <- model_parallel$coefficients[[2]]
b2_parallel <- model_parallel$coefficients[[3]]

M2_male_line <- (b0_parallel + b2_parallel) + b1_parallel * grid
M2_female_line <- b0_parallel + b1_parallel * grid

plot(data$vitamin, data$growth,
     pch = data$gender_dummy + 1,
     col = ifelse(data$gender_dummy == 1, "blue", "red"),
     xlab = "vitamin",
     ylab = "growth",
     sub = "Male(=1), Female(=0)")
legend("topleft",
       c("Male", "Female"),
       pch = c(2, 1),
       col = c("blue", "red"),
       lty = c(1, 2),
       bty = "n")

lines(grid, M2_male_line, col = "blue", lty = 1, lwd = 2)
lines(grid, M2_female_line, col = "red", lty = 2, lwd = 2)
```

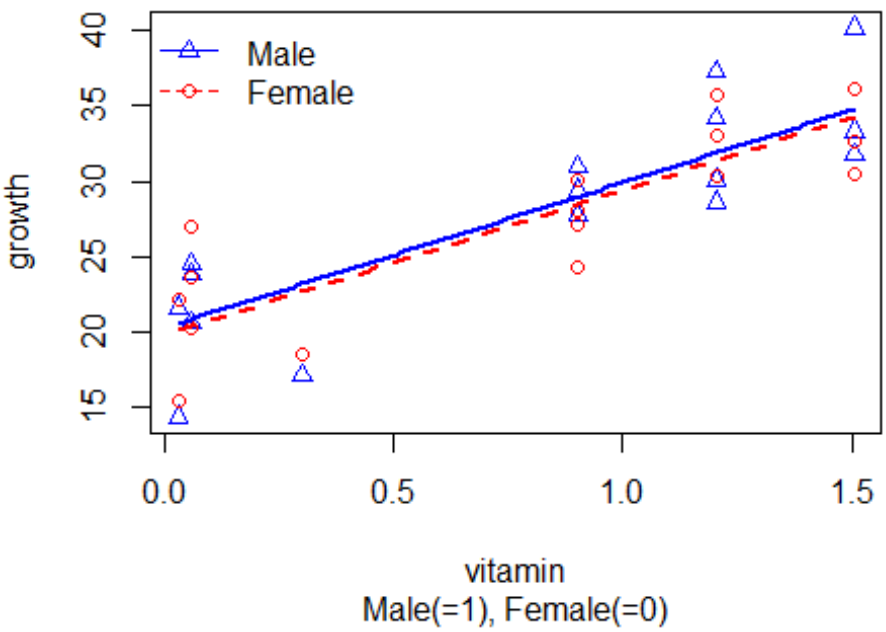

```r
# 성별 변수를 제거한 단순 회귀모델 (M3: Pooled Model)
model_pooled <- lm(growth ~ vitamin, data = data)
print(summary(model_pooled))
```

```
##
## Call:
## lm(formula = growth ~ vitamin, data = data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -5.9750 -2.1430 -0.1662  2.3527  6.3338
##
## Coefficients:
##            Estimate Std. Error t value Pr(>|t|)
## (Intercept)   19.984      1.037  19.269  < 2e-16 ***
## vitamin        9.674      1.077   8.979 5.28e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.464 on 30 degrees of freedom
## Multiple R-squared:  0.7288, Adjusted R-squared:  0.7198
## F-statistic: 80.62 on 1 and 30 DF,  p-value: 5.282e-10
```

```r
# M2 VS M3 비교
anova_intercept <- anova(model_parallel, model_pooled)
print(anova_intercept)
```

```
## Analysis of Variance Table
##
## Model 1: growth ~ vitamin + gender_dummy
## Model 2: growth ~ vitamin
##   Res.Df    RSS Df Sum of Sq      F Pr(>F)
## 1     29 357.85
## 2     30 359.89 -1   -2.0449 0.1657 0.6869
```

```r
#최종 모델 비교
models <- list(
  M1_Full = model_full,
  M2_Parallel = model_parallel,
  M3_Pooled = model_pooled
)

AIC_values <- sapply(models, AIC)
BIC_values <- sapply(models, BIC)
R2_values <- sapply(models, function(m) summary(m)$r.squared)
Adj_R2_values <- sapply(models, function(m) summary(m)$adj.r.squared)

comparison_table <- data.frame(
  Model = names(models),
  R2 = round(R2_values, 4),
  Adj_R2 = round(Adj_R2_values, 4),
  AIC = round(AIC_values, 2),
```

```
  BIC = round(BIC_values, 2)
)

print(comparison_table)

##                   Model     R2 Adj_R2    AIC    BIC
## M1_Full         M1_Full 0.7353 0.7069 177.48 184.81
## M2_Parallel M2_Parallel 0.7303 0.7117 176.07 181.93
## M3_Pooled     M3_Pooled 0.7288 0.7198 174.25 178.65

par(mfrow=c(2, 2))
plot(model_pooled)
```

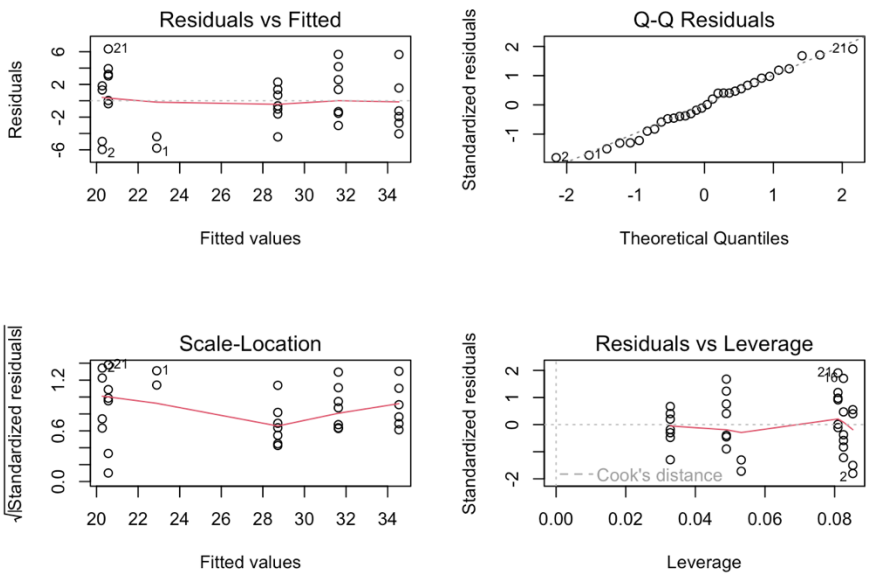

9.4

응용회귀분석 1 조

```
getwd()

## [1] "C:/Users/user/Documents/R_DA"

setwd("C:/Users/user/Documents/R_DA")
library(readxl)
library(car)
library(corrplot)

data <- read_excel("table9.4_turkey.xlsx")
data

## # A tibble: 13 × 5
##        x     y Origin    z1    z2
##    <dbl> <dbl> <chr>  <dbl> <dbl>
##  1    28  13.3 G         1     0
##  2    20   8.9 G         1     0
##  3    32  15.1 G         1     0
##  4    22  10.4 G         1     0
##  5    29  13.1 V         0     1
##  6    27  12.4 V         0     1
##  7    28  13.2 V         0     1
##  8    26  11.8 V         0     1
##  9    21  11.5 W         0     0
## 10    27  14.2 W         0     0
## 11    29  15.4 W         0     0
## 12    23  13.1 W         0     0
## 13    25  13.8 W         0     0

str(data)

## tibble [13 × 5] (S3: tbl_df/tbl/data.frame)
##  $ x     : num [1:13] 28 20 32 22 29 27 28 26 21 27 ...
##  $ y     : num [1:13] 13.3 8.9 15.1 10.4 13.1 12.4 13.2 11.8 11.5
14.2 ...
##  $ Origin: chr [1:13] "G" "G" "G" "G" ...
##  $ z1    : num [1:13] 1 1 1 1 0 0 0 0 0 0 ...
##  $ z2    : num [1:13] 0 0 0 0 1 1 1 1 0 0 ...

head(data)

## # A tibble: 6 × 5
##       x     y Origin    z1    z2
##   <dbl> <dbl> <chr>  <dbl> <dbl>
## 1    28  13.3 G         1     0
## 2    20   8.9 G         1     0
## 3    32  15.1 G         1     0
## 4    22  10.4 G         1     0
```

```
## 5    29  13.1 V          0     1
## 6    27  12.4 V          0     1
```

```r
summary(data)
```

```
##        x              y           Origin               z1
##  Min.   :20.00   Min.   : 8.90   Length:13         Min.   :0.0000
##  1st Qu.:23.00   1st Qu.:11.80   Class :character   1st Qu.:0.0000
##  Median :27.00   Median :13.10   Mode  :character   Median :0.0000
##  Mean   :25.92   Mean   :12.78                     Mean   :0.3077
##  3rd Qu.:28.00   3rd Qu.:13.80                     3rd Qu.:1.0000
##  Max.   :32.00   Max.   :15.40                     Max.   :1.0000
##        z2
##  Min.   :0.0000
##  1st Qu.:0.0000
##  Median :0.0000
##  Mean   :0.3077
##  3rd Qu.:1.0000
##  Max.   :1.0000
```

```r
data$Origin <- factor(data$Origin, levels = c("W", "G", "V"))

# 기술 통계량
library(dplyr)

summary_stats_turkey <- data %>%
  group_by(Origin) %>%
  summarise(
    N = n(),
    mean_Y = mean(y),
    sd_Y = sd(y),
    mean_X = mean(x),
    sd_X = sd(x)
  )

print(summary_stats_turkey)
```

```
## # A tibble: 3 × 6
##   Origin     N mean_Y  sd_Y mean_X  sd_X
##   <fct>  <int>  <dbl> <dbl>  <dbl> <dbl>
## 1 W          5   13.6 1.44    25    3.16
## 2 G          4   11.9 2.80    25.5  5.51
## 3 V          4   12.6 0.655   27.5  1.29
```

```r
# 히스토그램 (Histogram)
par(mfrow=c(1, 2))

hist(data$y,
     main = "체중 (Y)",
     xlab = "체중 (pound)",
     ylab = "Frequency",
     col = "lightblue")
```

```r
hist(data$x,
     main = "나이 (X)",
     xlab = "나이 (weeks)",
     ylab = "Frequency",
     col = "lightgreen")
```

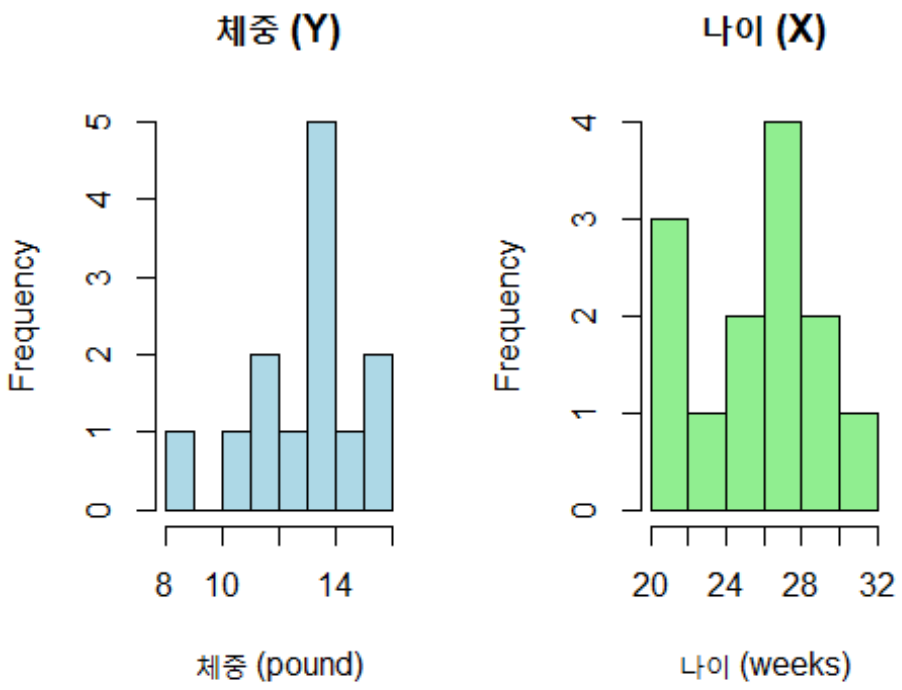


```r
# 박스플롯 (Boxplot)
par(mfrow=c(1, 2))

boxplot(y ~ Origin, data = data,
        main = "체중 (Y)",
        xlab = "원산지 (Origin)",
        ylab = "체중 (Y)",
        col = c("lightgrey", "red", "blue")) # W, G, V 순서

boxplot(x ~ Origin, data = data,
        main = "나이 (X) ",
        xlab = "원산지 (Origin)",
        ylab = "나이 (X)",
        col = c("lightgrey", "red", "blue"))
```

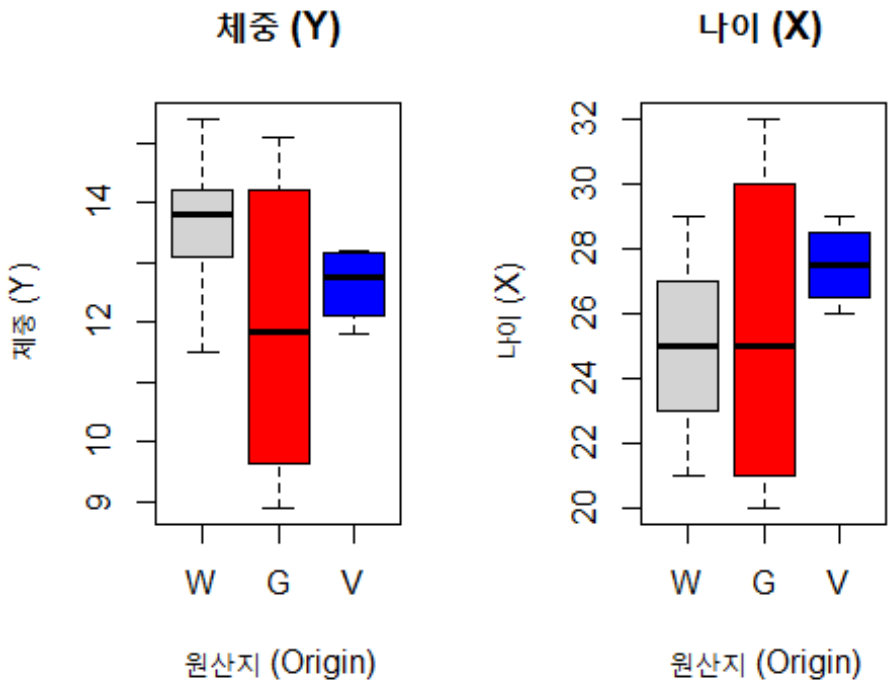


```r
par(mfrow=c(1, 1))


# M1: Full Model (기울기 다름)
model_full_turkey <- lm(y ~ x * Origin, data = data)
print(summary(model_full_turkey))

##
## Call:
## lm(formula = y ~ x * Origin, data = data)
##
## Residuals:
##    Min     1Q Median     3Q    Max
##  -0.32  -0.23   0.01   0.20   0.39
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.47500    1.26351   1.959   0.0910 .
## x            0.44500    0.05022   8.861 4.72e-05 ***
## OriginG     -3.45412    1.53054  -2.257   0.0586 .
## OriginV     -2.77500    4.10854  -0.675   0.5211
## x:OriginG    0.06104    0.06025   1.013   0.3447
## x:OriginV    0.02500    0.15066   0.166   0.8729
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3176 on 7 degrees of freedom
## Multiple R-squared:  0.9821, Adjusted R-squared:  0.9693
## F-statistic: 76.74 on 5 and 7 DF,  p-value: 5.849e-06
```

```r
new_data <- expand.grid(x = seq(min(data$x), max(data$x), length.out =
100),
                        Origin = levels(data$Origin))

new_data$pred_M1 <- predict(model_full_turkey, newdata = new_data)

plot(data$x, data$y,
     pch = c(17, 16, 15)[as.numeric(data$Origin)], # W=삼각형, G=원, V=사각
형
     col = c("gray50", "red", "blue")[as.numeric(data$Origin)], # W=회색,
G=빨강, V=파랑
     xlab = "나이 (X, weeks)",
     ylab = "체중 (Y, pound)",
     main = "M1: Full Model (기울기 다름)",
     ylim = range(data$y),
     xlim = range(data$x))

for (origin_level in levels(data$Origin)) {
  sub_data <- subset(new_data, Origin == origin_level)
  color_index <- as.numeric(factor(origin_level, levels =
levels(data$Origin)))
  lines(sub_data$x, sub_data$pred_M1,
        col = c("gray50", "red", "blue")[color_index],
        lty = 1, lwd = 2)
}

# 범례
legend("topleft",
       legend = levels(data$Origin),
       col = c("gray50", "red", "blue"),
       pch = c(17, 16, 15),
       lwd = 2,
       lty = 1,
       bty = "n",
       cex = 0.8)
```

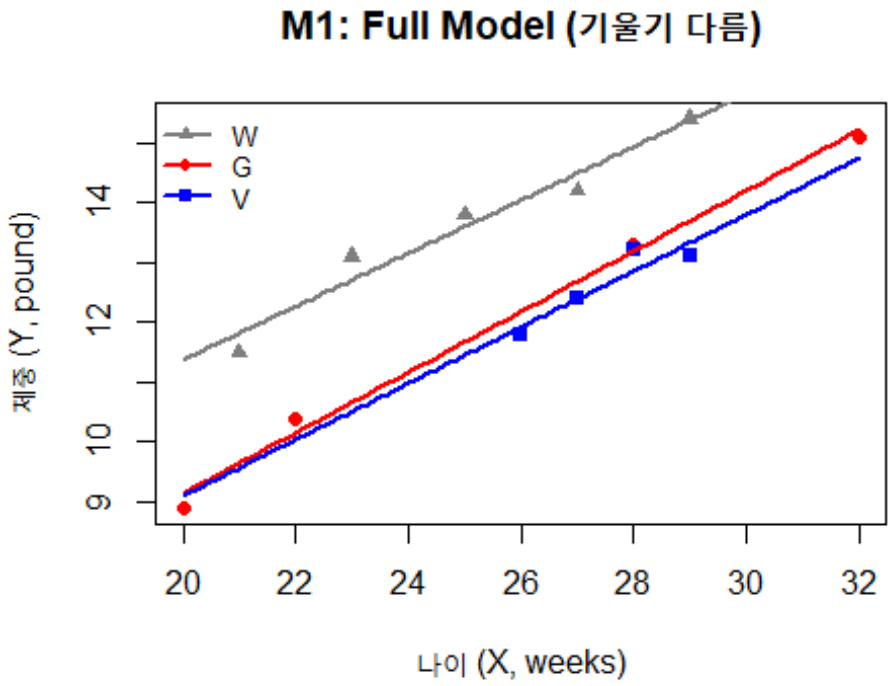


```
# M2: Parallel Model (기울기 같음)
model_parallel_turkey <- lm(y ~ x + Origin, data = data)
print(summary(model_parallel_turkey))

##
## Call:
## lm(formula = y ~ x + Origin, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.37353 -0.15294  0.01103  0.17868  0.47353
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.43088    0.65744   2.176   0.0575 .
## x            0.48676    0.02574  18.908 1.49e-08 ***
## OriginG     -1.91838    0.20180  -9.506 5.45e-06 ***
## OriginV     -2.19191    0.21143 -10.367 2.65e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3002 on 9 degrees of freedom
## Multiple R-squared:  0.9794, Adjusted R-squared:  0.9726
## F-statistic: 142.8 on 3 and 9 DF,  p-value: 6.6e-08

new_data$pred_M2 <- predict(model_parallel_turkey, newdata = new_data)

plot(data$x, data$y,
     pch = c(17, 16, 15)[as.numeric(data$Origin)],
```

```
     col = c("gray50", "red", "blue")[as.numeric(data$Origin)],
     xlab = "나이 (X, weeks)",
     ylab = "체중 (Y, pound)",
     main = "M2: Parallel Model (기울기 같음)",
     ylim = range(data$y),
     xlim = range(data$x))

for (origin_level in levels(data$Origin)) {
  sub_data <- subset(new_data, Origin == origin_level)
  color_index <- as.numeric(factor(origin_level, levels =
levels(data$Origin)))
  lines(sub_data$x, sub_data$pred_M2,
        col = c("gray50", "red", "blue")[color_index],
        lty = 2, lwd = 1) # 점선
}

legend("topleft",
       legend = levels(data$Origin),
       col = c("gray50", "red", "blue"),
       pch = c(17, 16, 15),
       lwd = 2,
       lty = 2,
       bty = "n",
       cex = 0.8)
```

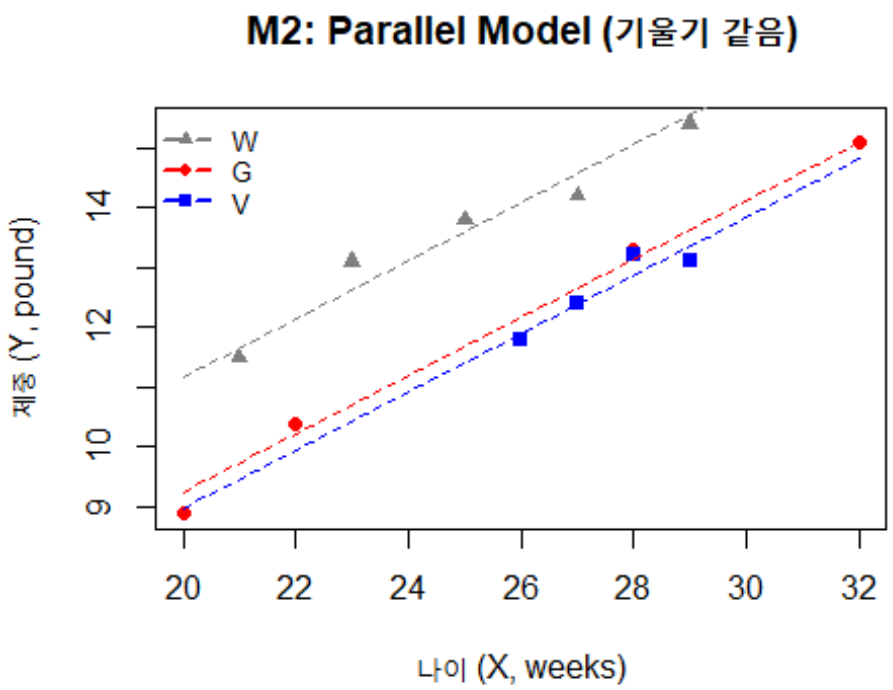

```r
# M3: Pooled Model (통합 모델)
model_pooled_turkey <- lm(y ~ x, data = data)
print(summary(model_pooled_turkey))
```

```
##
## Call:
## lm(formula = y ~ x, data = data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -1.4167 -0.8333 -0.3500  0.9667  1.5333
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.98333    2.33273    0.85 0.413327
## x            0.41667    0.08922    4.67 0.000682 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.096 on 11 degrees of freedom
## Multiple R-squared:  0.6647, Adjusted R-squared:  0.6343
## F-statistic: 21.81 on 1 and 11 DF,  p-value: 0.0006824
```

```r
# M1 VS M2
print(anova(model_full_turkey, model_parallel_turkey))
```

```
## Analysis of Variance Table
##
## Model 1: y ~ x * Origin
## Model 2: y ~ x + Origin
##   Res.Df     RSS Df Sum of Sq      F Pr(>F)
## 1      7 0.70618
## 2      9 0.81118 -2    -0.105 0.5204 0.6156
```

```r
# M2 VS M3
print(anova(model_parallel_turkey, model_pooled_turkey))
```

```
## Analysis of Variance Table
##
## Model 1: y ~ x + Origin
## Model 2: y ~ x
##   Res.Df     RSS Df Sum of Sq     F    Pr(>F)
## 1      9  0.8112
## 2     11 13.2150 -2   -12.404 68.81 3.517e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
par(mfrow=c(2, 2))
plot(model_parallel_turkey)
```

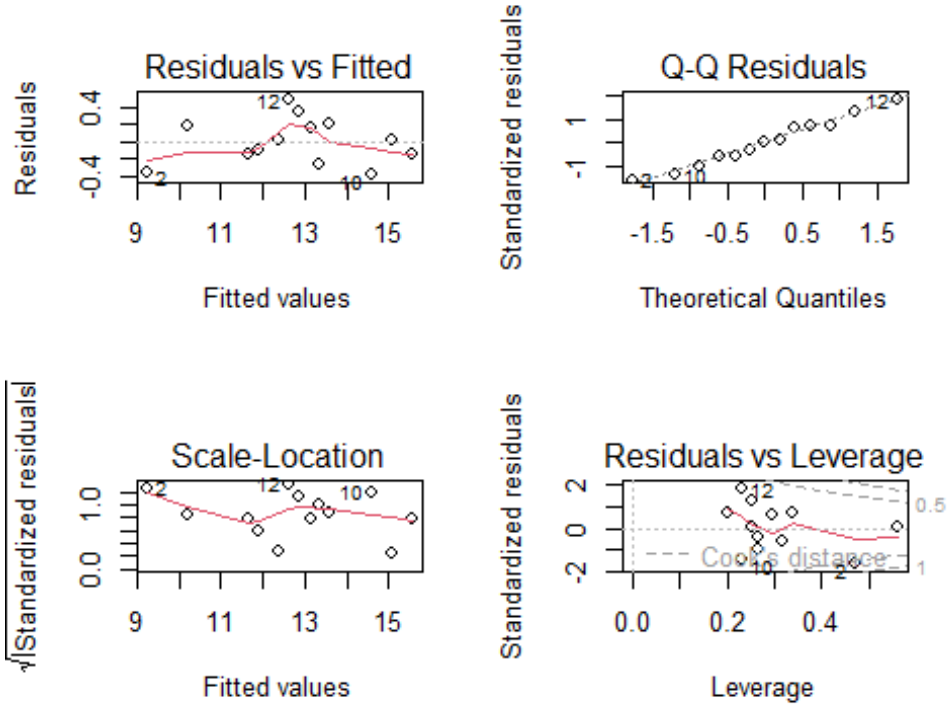
Residuals vs Fitted
Residuals
Fitted values
Q-Q Residuals
Standardized residuals
Theoretical Quantiles
Scale-Location
√|Standardized residuals|
Fitted values
Residuals vs Leverage
Standardized residuals
Cook's distance
Leverage